ČSOB

Retail Credit Risk Analytics

Automatizovaný monitoring rizikovosti portfolia

Technická dokumentace · Verze 1.0 · 2025

Autor:	Rudolf Munzig
Pozice:	Junior analytik úvěrových rizik
Projekt:	Portfolio Risk Monitoring – BankRisk_DB
Datum:	Březen 2025
Technologie:	SQL Server · Python · Power BI · pandas · pyodbc

Obsah

Obsah 2
1 Přehled projektu 3
1.1 Architektura řešení 3
1.2 Cíle projektu 3
1.3 Klíčové metriky portfolia 3
2 Databázová struktura 4
2.1 Schéma databáze 4
2.2 Vytvoření databáze 4
2.3 Dimenzionální tabulky 4
2.3.1 DimClients – tabulka klientů 4
2.3.2 DimProducts – katalog produktů 5
2.4 Faktová tabulka FactLoans 5
2.5 Vložení testovacích dat – outliery 6
3 Analytické View – v_Risk_Report 7
3.1 Klasifikační schéma rizika 7
3.2 SQL kód View 7
4 Python automatizace 9
4.1 Instalace závislostí 9
4.2 Konfigurace připojení 9
4.3 Hlavní logika skriptu 9
5 Power BI – propojení přes Power Query 11
5.1 Proč Power Query místo statického importu? 11
5.2 Jak napojit Power BI na BankRisk_DB 11
5.3 M kód pro Power Query Editor 11
6 Průvodce spuštěním v SSMS 13
6.1 Krok za krokem 13
6.2 Řešení nejčastějších chyb 13
7 Výstupní data a závěr 14
7.1 Struktura CSV výstupu 14
7.2 Shrnutí a doporučení pro rozvoj 14

1 Přehled projektu

Tato dokumentace popisuje kompletní implementaci systému pro automatizovaný monitoring rizikovosti portfolia retailových úvěrů. Projekt byl navržen jako demonstrační portfolio kus pro pozici Junior analytik úvěrových rizik v ČSOB.

1.1 Architektura řešení

Systém se skládá ze tří vzájemně propojených vrstev:

Vrstva	Technologie	Popis
Datová vrstva	SQL Server 2019+ | SSMS	Databáze BankRisk_DB · 3 tabulky · 1 View
Analytická vrstva	Python 3.10+ | pandas | pyodbc	Automatický export kritických případů do CSV
Vizualizační vrstva	Power BI Desktop | Power Query	Live dashboard napojený přímo na SQL View

1.2 Cíle projektu

- Simulovat reálné portfolio 25 retailových úvěrů s českou demografií
- Implementovat riziková pásma dle metodiky Basel III / EBA Guidelines
- Identifikovat a označit outliery – klienty s extrémní rizikovostí
- Automatizovat export kritických případů pro oddělení vymáhání
- Demonstrovat propojení SQL → Python → Power BI v bankovním kontextu

1.3 Klíčové metriky portfolia

Počet úvěrů	Celková expozice	NPL ratio	Outliery
25	**~67,5 mil. CZK**	**~16 %**	**2 (DPD > 120)**

2 Databázová struktura

Databáze BankRisk_DB je postavena na hvězdicovém schématu (Star Schema), které je standardem pro analytické databáze v bankovnictví. Středem schématu je faktová tabulka FactLoans, obklopená dvěma dimenzionálními tabulkami.

2.1 Schéma databáze

ℹ Pro spuštění níže uvedených SQL skriptů potřebujete: SQL Server 2016 nebo novější (Express/Developer edice je zdarma). Stáhněte z: aka.ms/sqlexpressdownloads

2.2 Vytvoření databáze

Prvním krokem je vytvoření nové databáze s českým řazením znaků. Klíčové je nastavení COLLATE, které zajistí správné zobrazení háčků a čárek.

```
-- Krok 1: Vytvoření databáze BankRisk_DB
-- Bezpečné vytvoření databáze (pokud existuje, smažeme ji)
IF EXISTS (SELECT name FROM sys.databases WHERE name = 'BankRisk_DB')
BEGIN
    ALTER DATABASE BankRisk_DB SET SINGLE_USER WITH ROLLBACK IMMEDIATE;
    DROP DATABASE BankRisk_DB;
END
GO

CREATE DATABASE BankRisk_DB
    COLLATE Czech_CI_AS;  -- Podpora českých znaků (háčky, čárky)
GO

USE BankRisk_DB;  -- Přepne kontext na nově vytvořenou databázi
GO
```

2.3 Dimenzionální tabulky

2.3.1 DimClients – tabulka klientů

Obsahuje demografické informace o každém klientovi. Klíčový sloupec je SegmentKlienta – klienti označení jako 'High Risk' jsou outliery a budou mít v rizikovém View speciální zacházení.

```
-- Struktura tabulky DimClients
CREATE TABLE DimClients (
    ClientID        INT           PRIMARY KEY,        -- Unikátní ID klienta
    Jmeno           NVARCHAR(100) NOT NULL,           -- České jméno
    DatumNarozeni   DATE          NOT NULL,           -- Datum narození
    Mesto           NVARCHAR(100) NOT NULL,           -- Město bydliště
    Zamestnani      NVARCHAR(100) NOT NULL,           -- Zaměstnání
    MesicniPrijem   DECIMAL(12,2) NOT NULL,           -- Čistý příjem v CZK
```

```
    KreditniSkore    INT           NOT NULL,           -- Skóre 300-850
    SegmentKlienta   NVARCHAR(50)  NOT NULL            -- Retail/Premium/High
Risk
);
GO
```

2.3.2 DimProducts – katalog produktů

Katalog úvěrových produktů banky. Umožňuje segmentaci portfolia podle typu produktu (hypotéky vs. spotřebitelské úvěry) – zásadní pro výpočet LGD a rizikových vah.

```
-- Struktura tabulky DimProducts
CREATE TABLE DimProducts (
    ProductID        INT           PRIMARY KEY,
    NazevProduktu    NVARCHAR(100) NOT NULL,
    TypProduktu      NVARCHAR(50)  NOT NULL,           --
Hypoteční/Spotřebitelský/Revolvingový
    UrokovaSazba     DECIMAL(5,2)  NOT NULL,           -- Roční sazba v %
    MaxVyseUveru     DECIMAL(15,2) NOT NULL,           -- Maximální výše v CZK
    MinDoba          INT           NOT NULL,           -- Min. splatnost v
měsících
    MaxDoba          INT           NOT NULL            -- Max. splatnost v
měsících
);
GO
```

2.4 Faktová tabulka FactLoans

Klíčová tabulka projektu. Každý řádek reprezentuje jeden aktivní úvěr. Sloupec DPD (Days Past Due) je základem pro výpočet rizikové kategorie.

```
-- Struktura tabulky FactLoans
CREATE TABLE FactLoans (
    LoanID           INT           PRIMARY KEY,
    ClientID         INT           NOT NULL REFERENCES DimClients(ClientID),
    ProductID        INT           NOT NULL REFERENCES DimProducts(ProductID),
    DatumCerpani     DATE          NOT NULL,
    JistinaCZK       DECIMAL(15,2) NOT NULL,           -- Původní výše úvěru
    ZbyvatekCZK      DECIMAL(15,2) NOT NULL,           -- Aktuální zůstatek
    MesicniSplatka   DECIMAL(10,2) NOT NULL,
    DPD              INT           NOT NULL,           -- *** Klíčový rizikový
indikátor ***
    PocetSplatek     INT           NOT NULL,
    ZbyvajiSplatky   INT           NOT NULL,
    Kolateral        NVARCHAR(100) NULL,               -- NULL = bez zajištění
    DatumPosledniSp  DATE          NOT NULL
);
GO
```

2.5 Vložení testovacích dat – outliery

Databáze obsahuje 2 záměrné outliery: **Igor Švarc (DPD = 157 dní, dluh 6,2 mil. CZK)** a **Dagmar Blahutová (DPD = 134 dní, dluh 5,8 mil. CZK)**. Oba klienti jsou označeni v DimClients segmentem 'High Risk'.

```
-- Vložení outlierů do FactLoans
-- *** OUTLIER #1 – Igor Švarc ***
-- Dluh: 6 200 000 CZK | DPD: 157 dní | Příjem: 8 000 CZK | Skóre: 310
INSERT INTO FactLoans VALUES
(124, 24, 1, '2018-01-10', 7200000.00, 6200000.00, 28500.00,
 157, 360, 210, N'Dům Praha (exekuce)', '2024-10-25');

-- *** OUTLIER #2 – Dagmar Blahutová ***
-- Dluh: 5 800 000 CZK | DPD: 134 dní | Příjem: 6 500 CZK | Skóre: 290
INSERT INTO FactLoans VALUES
(125, 25, 2, '2019-05-22', 6900000.00, 5800000.00, 25000.00,
 134, 300, 185, N'Byt Ostrava (soudní spor)', '2024-11-15');
GO
```

3 Analytické View – v_Risk_Report

View je virtuální tabulka – SQL Server ji sestaví dynamicky při každém dotazu. Neukládá data, pouze definuje logiku. To znamená, že každý pohled na v_Risk_Report automaticky reflektuje nejnovější stav databáze.

3.1 Klasifikační schéma rizika

Kategorizace odpovídá metodice EBA (European Banking Authority) a je v souladu s Basel III, IFRS 9 a metodikou ČNB pro retailové portfólio:

Kategorie	DPD rozsah	Riziková váha	Popis
Performing	0 dní	Nízká	Řádně splácející úvěr, bez prodlení
Watch List	1 – 30 dní	Střední	Sledovaný úvěr, včasná intervence
Non-Performing	31 – 90 dní	Vysoká	Nesplácený úvěr, aktivní jednání s klientem
Default	91 – 119 dní	Kritická	Defaultní úvěr, předáno vymáhání
High Priority	120+ dní	**OUTLIER**	Extrémní případ – okamžitá právní akce, exekuce

3.2 SQL kód View

```
-- View v_Risk_Report - kompletní definice
CREATE OR ALTER VIEW v_Risk_Report AS
SELECT
    -- Identifikace klienta a úvěru
    fl.LoanID,
    fl.ClientID,
    dc.Jmeno            AS KlientJmeno,
    dc.Mesto,
    dc.SegmentKlienta,
    dc.KreditniSkore,

    -- Produktová informace
    dp.NazevProduktu,
    dp.TypProduktu,

    -- Finanční ukazatele
    fl.JistinaCZK,
    fl.ZbyvatekCZK,
    fl.MesicniSplatka,
    fl.DPD,

    -- DTI = Debt-to-Income ratio (splátka / příjem * 100)
    -- Hodnota nad 40 % je varovným signálem
    CAST(
        (fl.MesicniSplatka / NULLIF(dc.MesicniPrijem, 0)) * 100
    AS DECIMAL(5,1))    AS DTI_Procent,
```

```sql
    -- *** KLASIFIKACE RIZIKA dle Basel III ***
    CASE
        WHEN fl.DPD = 0                    THEN 'Performing'
        WHEN fl.DPD BETWEEN 1  AND 30      THEN 'Watch List'
        WHEN fl.DPD BETWEEN 31 AND 90      THEN 'Non-Performing'
        WHEN fl.DPD > 90
             AND dc.SegmentKlienta = 'High Risk'
                                           THEN 'High Priority'
        WHEN fl.DPD > 90                   THEN 'Default'
    END                 AS RizikovaKategorie,

    fl.DatumPosledniSp,
    DATEDIFF(DAY, fl.DatumPosledniSp, GETDATE()) AS DniOdPosledniSplatky,
    ISNULL(fl.Kolateral, N'Bez zajištění')        AS Kolateral,
    GETDATE()           AS DatumSestaveníReportu

FROM FactLoans      fl
INNER JOIN DimClients  dc ON fl.ClientID  = dc.ClientID
INNER JOIN DimProducts dp ON fl.ProductID = dp.ProductID;
GO
```

4 Python automatizace

Python skript se připojí k BankRisk_DB přes ODBC driver, načte data z View v_Risk_Report a vygeneruje CSV soubor s kritickými případy. Skript je navržen tak, aby jej bylo možné spouštět ručně i automaticky (Task Scheduler, CI/CD pipeline).

4.1 Instalace závislostí

Před prvním spuštěním je nutné nainstalovat Python balíčky. Otevřete Command Prompt a spusťte:

```
-- Instalace Python závislostí
# Instalace potřebných balíčků (spusťte v Command Prompt)
pip install pandas pyodbc

# Ověření instalace
python -c "import pandas, pyodbc; print('OK')"
```

⚠ Pro Windows potřebujete také nainstalovat ODBC Driver pro SQL Server. Stáhněte 'ODBC Driver 18 for SQL Server' z Microsoft Download Center (vyhledejte: 'download odbc driver sql server').

4.2 Konfigurace připojení

```
-- Nastavení DB_CONFIG v Python skriptu
# Konfigurace připojení k databázi
# Upravte SERVER na název vašeho SQL Server instance
DB_CONFIG = {
    'driver':   '{ODBC Driver 18 for SQL Server}',
    'server':   'localhost',        # nebo 'PC-JMENO\\SQLEXPRESS'
    'database': 'BankRisk_DB',
    'trusted':  'yes',              # Windows autentifikace (bez hesla)
    'encrypt':  'optional',
    'trust_server_certificate': 'yes'
}
```

4.3 Hlavní logika skriptu

```
-- Jádro skriptu - dotaz a export
import pandas as pd
import pyodbc

# SQL dotaz - vybere pouze Default a High Priority případy
SQL_QUERY = """
    SELECT KlientJmeno, Mesto, ZbyvatekCZK, DPD,
```

```
            RizikovaKategorie, DatumPosledniSp
    FROM    v_Risk_Report
    WHERE   RizikovaKategorie IN ('Default', 'High Priority')
    ORDER   BY DPD DESC
"""

# Připojení a načtení dat
with pyodbc.connect(conn_str, timeout=15) as conn:
    df = pd.read_sql(SQL_QUERY, conn)

# Export do CSV s českým formátováním
df.to_csv(
    'Kriticke_pripady_vymahani.csv',
    sep=';',                # Středník = CZ standard pro Excel
    encoding='utf-8-sig',   # BOM = správné háčky v Excelu
    decimal=',',            # Desetinná čárka (CZ formát)
    date_format='%d.%m.%Y' # Formát data
)
```

5 Power BI – propojení přes Power Query

Tato sekce popisuje klíčovou výhodu živého propojení Power BI s SQL Serverem oproti tradičnímu statickému importu dat. Pochopení tohoto rozdílu je zásadní pro každého risk analytika, který pracuje s reportingem.

5.1 Proč Power Query místo statického importu?

✕ Statický import (Excel / CSV)	✓ Power Query – Live Connection
Data jsou kopií stavu ke dni importu	Data jsou vždy aktuální – čerpají přímo z DB
Při změně DPD musíte znovu exportovat CSV	Stačí kliknout 'Obnovit' – Power BI data přenačte
Riziko práce s neaktuálními daty (compliance risk)	Vždy reportujete na reálném stavu portfolia
Každý analytik má jinou verzi dat	Jeden zdroj pravdy (Single Source of Truth)
Nelze naplánovat automatické obnovení	Lze naplánovat automatický refresh v Power BI Service

5.2 Jak napojit Power BI na BankRisk_DB

Postup krok za krokem pro začátečníka:

1. Otevřete Power BI Desktop → klikněte 'Načíst data' → vyberte 'SQL Server'.
2. Do pole 'Server' zadejte název vašeho SQL Serveru (např. localhost nebo PC-JMENO\SQLEXPRESS).
3. Do pole 'Databáze' zadejte: BankRisk_DB
4. V sekci 'Rozšířené možnosti' do pole SQL zadejte dotaz:

```
-- Power Query - SQL dotaz do Power BI
-- Tento dotaz Power BI spustí při každém obnovení reportu
SELECT *
FROM   v_Risk_Report
ORDER  BY DPD DESC;
```

5. Klikněte 'OK' → přihlaste se Windows autentifikací → data se načtou.
6. V Power BI vytvořte vizualizace: pruhový graf kategorií, tabulku outlierů, KPI karty.
7. Pro automatické obnovení nastavte: Domů → Transformovat data → nastavte plán obnovení.

5.3 M kód pro Power Query Editor

Pokud chcete připojení nakonfigurovat přímo v Power Query (pokročilý způsob):

```
-- M kód - Power Query Editor
// Power Query (M jazyk) - direktní připojení k SQL View
let
```

```
    // Krok 1: Připojení k SQL Serveru
    Zdroj = Sql.Database(
        "localhost",           // Název serveru
        "BankRisk_DB"          // Název databáze
    ),

    // Krok 2: Výběr View z databáze
    View = Zdroj{[Schema="dbo",Item="v_Risk_Report"]}[Data],

    // Krok 3: Filtr pouze kritických kategorií (volitelné)
    KritickeKategorie = Table.SelectRows(
        View,
        each [RizikovaKategorie] = "Default"
           or [RizikovaKategorie] = "High Priority"
    )
in
    KritickeKategorie
```

6 Průvodce spuštěním v SSMS

Tato sekce je určena pro začátečníky. Popisuje přesný postup, jak celý projekt nastavit od nuly v SQL Server Management Studio (SSMS).

ℹ SSMS je zdarma ke stažení z Microsoft webu. Vyhledejte 'Download SQL Server Management Studio'. Instalace zabere cca 5 minut.

6.1 Krok za krokem

Krok	Akce	Detail
1	**Otevřít SSMS**	Spusťte SSMS → připojte se k serveru (Server type: Database Engine, Authentication: Windows Authentication)
2	**Nový dotaz**	Klikněte 'New Query' (Ctrl+N) → otevře se prázdné okno pro SQL kód
3	**Vložit SQL**	Zkopírujte celý obsah souboru BankRisk_DB_Setup.sql a vložte do okna dotazu
4	**Spustit**	Stiskněte F5 nebo klikněte 'Execute' – skript vytvoří databázi, tabulky a View
5	**Ověření**	V Object Exploreru (vlevo) rozbalte BankRisk_DB → Views → klikněte pravým na v_Risk_Report → Select Top 1000 Rows
6	**Python**	Otevřete Command Prompt ve složce se skriptem → spusťte: python generate_kriticke_pripady.py
7	**CSV výstup**	Zkontrolujte, že byl vygenerován soubor Kriticke_pripady_vymahani.csv ve stejné složce

6.2 Řešení nejčastějších chyb

⚠ Chyba 'Cannot connect to server': Zkontrolujte, zda je spuštěna služba SQL Server (hledejte 'SQL Server Configuration Manager' → SQL Server (MSSQLSERVER) musí být ve stavu Running).

⚠ Chyba 'pyodbc.OperationalError': ODBC Driver není nainstalován nebo název serveru v DB_CONFIG nesouhlasí. V SSMS zkopírujte přesný název serveru z okna připojení.

ℹ CSV soubor zobrazuje špatné znaky: Otevřete Excel → Data → Z textu/CSV → vyberte soubor → nastavte Origin: 65001 (UTF-8). Nebo dvakrát klikněte na soubor – Excel by měl kódování detekovat automaticky.

7 Výstupní data a závěr

7.1 Struktura CSV výstupu

Soubor Kriticke_pripady_vymahani.csv bude obsahovat následující sloupce:

Sloupec CSV	Datový typ	Popis
ID Uveru	Integer	Unikátní identifikátor úvěru z FactLoans
Jmeno klienta	Text	Celé jméno klienta z DimClients
Mesto	Text	Město bydliště klienta
Segment	Text	Zákaznický segment (High Risk pro outliery)
Produkt	Text	Název úvěrového produktu z DimProducts
Zustatek CZK	Decimal	Aktuální dlužná částka v CZK (desetinná čárka)
DPD - dny v prodleni	Integer	Počet dní od poslední splátky
DTI pct	Decimal	Poměr splátky k příjmu v procentech
Rizikova kategorie	Text	Default nebo High Priority
Kolateral	Text	Zajištění úvěru nebo 'Bez zajištění'

7.2 Shrnutí a doporučení pro rozvoj

Projekt demonstruje klíčové dovednosti požadované pro pozici Junior analytik úvěrových rizik: návrh datové struktury, SQL analytika, Python automatizace a základy BI reportingu.

Možná rozšíření projektu pro pokročilejší verzi:

- Implementace PD modelu (Probability of Default) pomocí logistické regrese v Python
- Výpočet ECL (Expected Credit Loss) dle IFRS 9 – Stage 1, 2, 3
- Napojení Power BI Service s automatickým denním refreshem dat
- Přidání historické tabulky FactLoans_History pro sledování migrace mezi kategoriemi
- Alerting – e-mailové upozornění při překročení prahu NPL ratio

Technická dokumentace · BankRisk_DB · Automatizovaný monitoring portfolia
Rudolf Munzig · Junior analytik úvěrových rizik · 2025